Universidad
Rey Juan Carlos
Escuela de Ingeniería
de Fuenlabrada

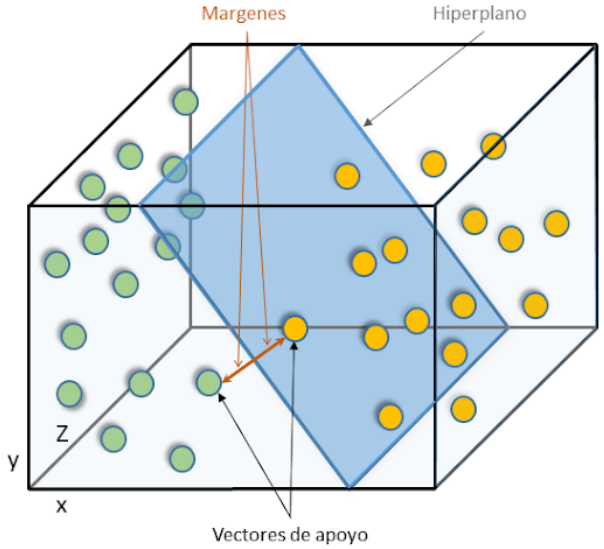

Visión Artificial

10. Reconocimiento de patrones

JOSÉ MIGUEL GUERRERO HERNÁNDEZ

EMAIL: JOSEMIGUEL.GUERRERO@URJC.ES

Índice de contenidos

Índice de contenidos

1. Introducción

- El **Machine Learning**, o aprendizaje automático o automatizado, tiene como objetivo desarrollar técnicas que permitan que los ordenadores, o máquinas con capacidad de procesamiento, aprendan
- Pero las máquinas no aprenden por sí mismas, están programadas para adaptar un algoritmo conforme reciben datos
  - Cuantos más datos reciben, mejores serán los algoritmos que crean, siempre y cuando los datos introducidos sean datos fiables y de calidad, ya que si se mete algún dato erróneo puede resultar en un mal aprendizaje
- Esto es posible en parte gracias a las redes neuronales

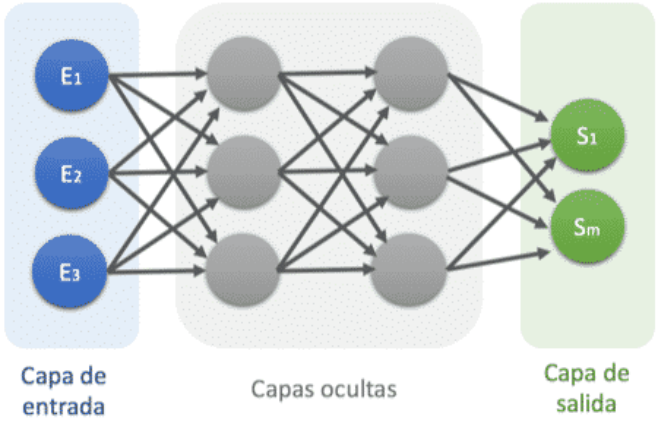

1. Introducción

- Mientras que con el **Machine Learning** hay que ayudar al ordenador indicándole qué son los datos introducidos, **aprendizaje supervisado**, en el **Deep Learning** se avanza en el concepto de **aprendizaje no supervisado**
- Los algoritmos DL son capaces de aprender sin intervención humana previa, sacando ellos mismos las conclusiones de todos los datos
- También es capaz de dotar a los objetos de un significado y manejar conceptos abstractos, no solo cosas materiales (son capaces de entender lo que están viendo)
- Al tener como base al Machine Learning, las **redes de neuronas** automáticas siguen presentes, realizando las mismas funciones, pero con un número de neuronas y capas bastante mayor y más sofisticadas
- Para poder llevar a cabo el aprendizaje de estas complejas y numerosas redes neuronales es necesario una gran capacidad de procesamiento (GPU)

1. Introducción

- En general, los algoritmos de aprendizaje se pueden dividir en dos:
  - **Aprendizaje supervisado**:
    - Los algoritmos de aprendizaje supervisado ajustan el modelo o función de clasificación mediante un **conjunto de datos cuya clase es conocida**, llamado **conjunto de entrenamiento**
    - Formalmente este conjunto se representa como $\{(x_1, y_1), \dots, (x_N, y_N)\}$, donde x_i es el i-ésimo vector del conjunto de entrenamiento mientras y_i es la clase a la que pertenece dicho vector
    - Una vez ajustado el modelo, la función de clasificación es capaz de asignar la clase y_k a la que pertenecen nuevos elementos x_k. El conjunto de elementos de clase desconocida se llama **conjunto de test**
  - **Aprendizaje no supervisado**:
    - Los algoritmos de aprendizaje no supervisado tratan de ajustar un modelo de clasificación a partir de un **conjunto de datos no etiquetados** (de los que no se conocen las clases a las que pertenecen) $\{x_1, \dots, x_N\}$
    - Para realizar este ajuste, el algoritmo debe encontrar de forma autónoma las características, regularidades y correlaciones de los datos, de forma que pueda separar las categorías similares entre sí

Índice de contenidos

2. Aprendizaje supervisado: K-NN

- El algoritmo de los **k vecinos más cercanos** (**k-NN**, o **k Nearest Neighbour**) es un algoritmo de clasificación supervisado basado en criterios de vecindad
- En particular, k-NN se basa en la idea de que los nuevos ejemplos serán clasificados con la misma clase que tengan la mayor cantidad de vecinos más parecidos a ellos del conjunto de entrenamiento
- Este algoritmo sigue un procedimiento que seguimos cada uno de nosotros al ver un ejemplo nuevo: vemos a qué se parece más de lo que conocemos, y lo metemos en la misma bolsa

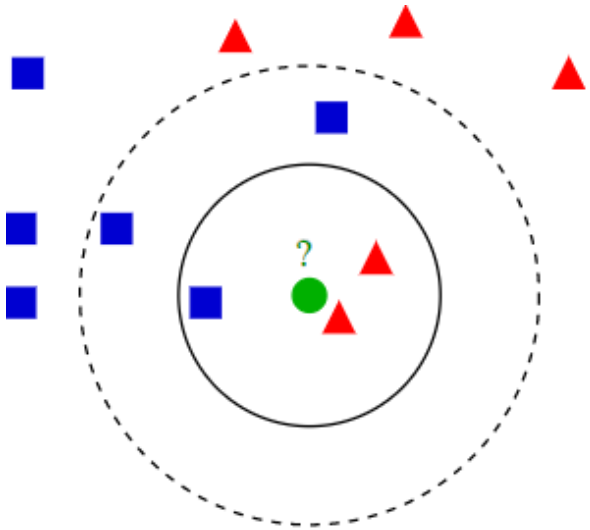

2. Aprendizaje supervisado: K-NN

- Su versión más **simple explora todo** el conocimiento almacenado en el conjunto de entrenamiento para determinar cuál será la clase a la que pertenece una nueva muestra, pero únicamente tiene en cuenta el vecino más próximo (más similar) a ella
- Es lógico pensar que es posible que no se esté aprovechando de forma eficiente toda la información que se podría extraer del conjunto de entrenamiento
- Con el objetivo de resolver esta posible deficiencia surge la **generalización de los k vecinos más cercanos** (k-NN), en la que se utiliza la información suministrada por los k ejemplos del conjunto de entrenamiento más cercanos al que queremos clasificar

2. Aprendizaje supervisado: K-NN

- Una variante de este algoritmo consiste en ponderar la contribución de cada vecino de acuerdo con la distancia entre él y la muestra a ser clasificada, dando mayor peso a los vecinos más cercanos frente a los que puedan estar más alejados
- Si x es el ejemplo que queremos clasificar, V son las posibles clases de clasificación, y $\{x_1, \dots, x_k\}$ es el conjunto de los k ejemplos de entrenamiento más cercanos, definimos el peso de x_i respecto a x como:

$$w_i = \frac{1}{d(x, x_i)^2}$$

- Y entonces la clase asignada a x es aquella que verifique que la suma de los pesos de sus representantes sea máxima, es decir:

$$argmax_{v \in V} \sum_{i=1}^{k} w_i$$

2. Aprendizaje supervisado: K-NN

- Esta variante es muy efectiva en muchos problemas prácticos. Es robusto ante el ruido de los datos y suficientemente efectivo en conjuntos de datos grandes

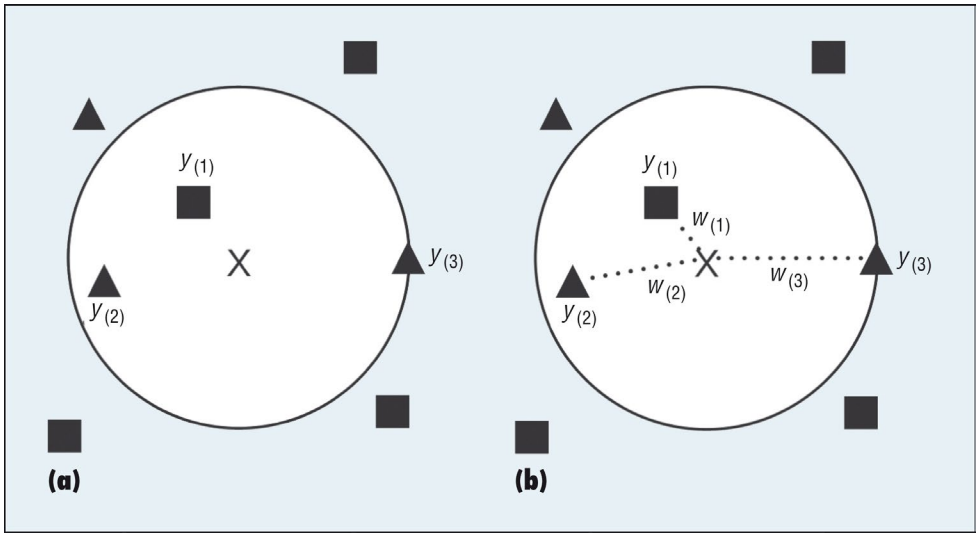

https://youtu.be/gdS0V35GqgQ

2. Aprendizaje supervisado: K-NN

- En el algoritmo k-NN existe el problema de que requiere de mucha memoria y tiempo de ejecución porque hay que almacenar continuamente todos los datos que definen el espacio de inicial
- Sin embargo, es muy probable que muchas de las muestras iniciales no sean necesarias para clasificar las demás, ya que su información es redundante con las otras existentes
- Para mitigar esto:
  - **k-NN Condensado**: dado un orden en los datos de entrada, cada ejemplo del conjunto se clasifica por medio de k-NN haciendo uso únicamente de los datos anteriores; si la clasificación obtenida coincide con la real, ese ejemplo se elimina de los datos, si no, permanece. Este método depende del orden en que se procesan los datos y tiene la desventaja de mantener ejemplos que pueden introducir ruido en el sistema
  - **k-NN Reducido**: es similar a la anterior, pero se comienza con el conjunto completo de datos, y se eliminan aquellos que no afectan a la clasificación del resto de datos de entrada. Al revés de lo que ocurre con la condensación, este método es capaz de eliminar las muestras que producen ruido, y guarda aquellas que son críticas para la clasificación

Índice de contenidos

2. Aprendizaje supervisado: SVM

- Las **Máquinas de Vectores Soporte** (SVM por sus siglas en inglés Support Vector Machines) (Vapnik, 1995) constituyen una de las técnicas de clasificación supervisada más potentes
- Se trata de un **clasificador biclase** (esto es, permite clasificar en dos clases), aunque la mayoría de las implementaciones de este (LIBSVM, LIBLINEAR) soportan clasificación multi-clase
- Al igual que cualquier clasificador supervisado biclase, el objetivo de un SVM es **inferir una frontera de decisión** (lineal o no) en el espacio de características, de modo que las observaciones posteriores se clasifiquen automáticamente en uno de los dos grupos definidos por dicha frontera (también conocida como **hiperplano**)

2. Aprendizaje supervisado: SVM

- La particularidad de SVM es que trata de generar dicho hiperplano de modo que maximice su separación con cada uno de los grupos

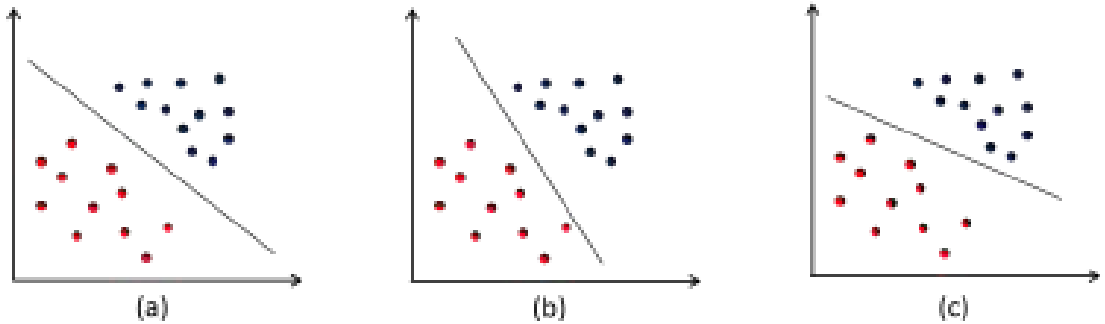

Diferentes hiperplanos

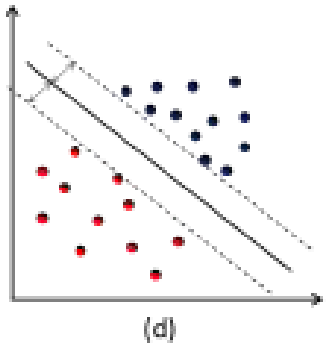

Hiperplano de margen máximo

2. Aprendizaje supervisado: SVM

- La forma general de la función de decisión SVM viene dada por la expresión:

$$f(x) = signo(w \cdot x + b)$$

donde:

- $f(x)$ es la función de decisión que clasifica las muestras de entrada
- x es el vector de características de entrada
- w es el vector de pesos
- b es el término de sesgo (también conocido como término de intercepción)
- $\cdot$ denota el producto escalar entre w y x
- $signo()$ es una función que devuelve el signo del resultado

2. Aprendizaje supervisado: SVM

- El objetivo de SVM es encontrar el **vector de pesos w** y el término de **sesgo b** que maximicen el margen entre las clases
- Esto se logra formulando un **problema de optimización** donde se minimiza la norma del vector de pesos sujeto a ciertas restricciones:

$$y_i(w \cdot x_i + b) \geq M$$

donde:

- M es el margen
- (x_i, y_i) son los puntos de datos de entrenamiento:
  - x_i vector de entrada
  - y_i etiquetas de clase $(+1\ o\ -1)$
- w es el vector de pesos
- b es el término de sesgo
- i representa cada punto de datos de entrenamiento

2. Aprendizaje supervisado: SVM

- La ecuación de la función de decisión $\boldsymbol{f(x)}$ se utiliza luego para **clasificar nuevas muestras** de entrada en una de las clases definidas por el hiperplano óptimo encontrado durante el entrenamiento
- La salida del sistema SVM es $\{+1, -1\}$, donde $+1$ y -1 están asociados a las clases C_1 y C_2 respectivamente

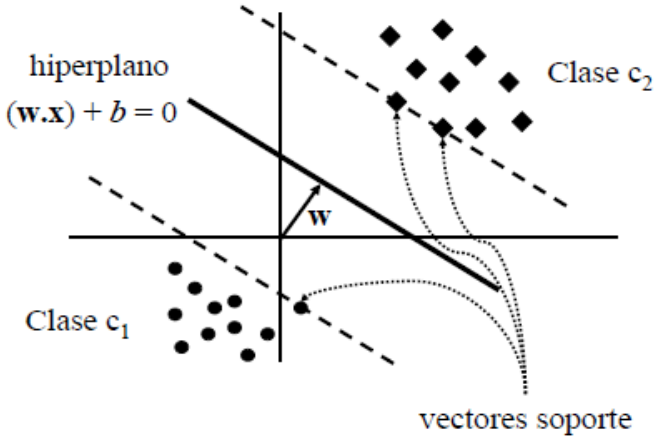

- Para el caso de **SVM no lineales**, se pueden utilizar **otras funciones de kernel**. En este caso, la ecuación de la función de decisión sigue siendo la misma, pero x representa el vector de características transformado

Índice de contenidos

2. Aprendizaje supervisado: Perceptrón

- **Red neuronal monocapa: Perceptrón simple**
  - La red neuronal monocapa se corresponde con la red neuronal más simple, está compuesta por una capa de neuronas que proyectan las entradas a una capa de neuronas de salida donde se realizan los diferentes cálculos

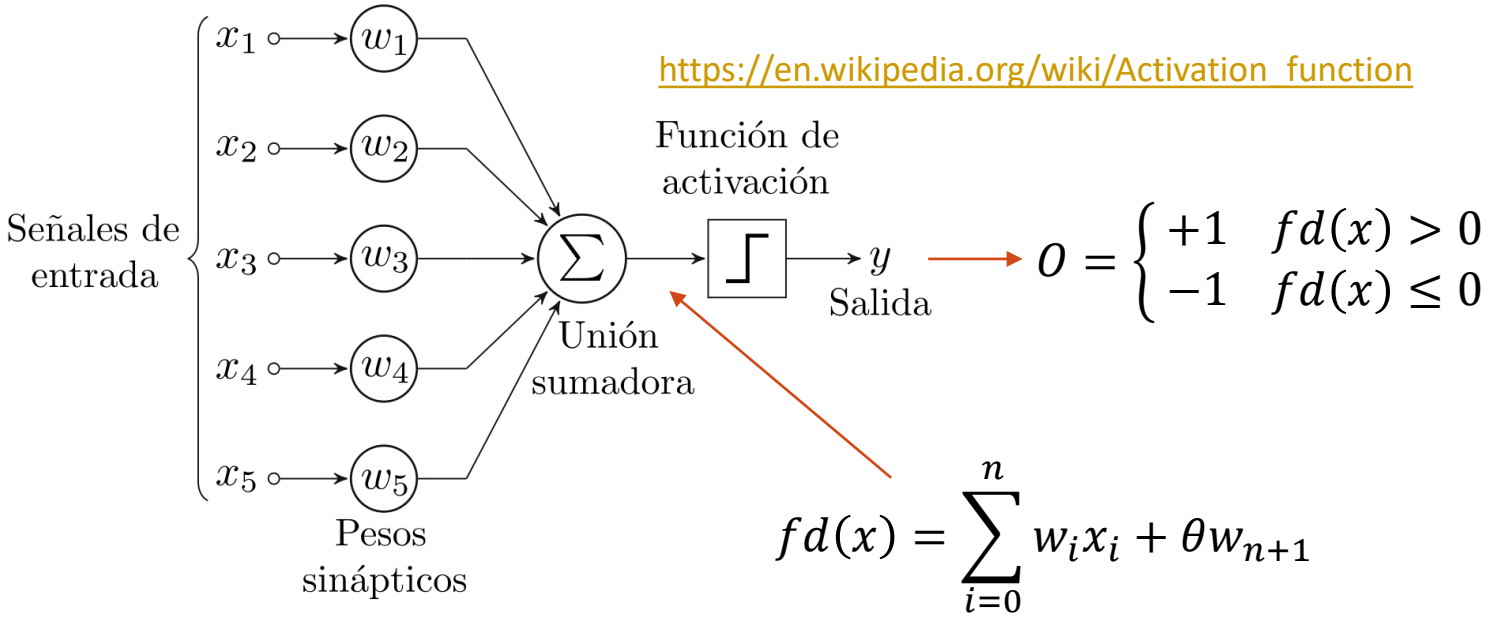

2. Aprendizaje supervisado: Perceptrón

- **Red neuronal monocapa: Perceptrón simple**
  - El **funcionamiento** del perceptrón es muy **sencillo**, simplemente lee los valores de entrada, suma todas las entradas de acuerdo con unos pesos, y el resultado lo introduce en una función de activación que genera el resultado final
  - El entrenamiento del perceptrón no es más que **determinar los pesos sinápticos y el umbral** que mejor hagan que la entrada se ajuste a la salida
  - Para la determinación de estas variables, se sigue un **proceso adaptativo**. El proceso comienza con valores aleatorios y se van modificando estos valores según la diferencia entre los valores deseados y los calculados por la red
  - En resumen, el perceptrón aprende de manera **iterativa**
  - Hay que tener en cuenta que el **perceptrón solo es capaz de representar funciones lineales** debido a que no dispone de capas ocultas como por ejemplo el perceptrón multicapa

2. Aprendizaje supervisado: Perceptrón

- **Red neuronal monocapa: Perceptrón simple**
  - Entrenamiento:
    1. **Inicialización de los pesos y del umbral**: inicialmente se asignan valores aleatorios a cada uno de los pesos $w_i \quad i = 1,2,..,n,n+1$ y al bias θ
    2. **Presentación de un nuevo par** (Entrada, Salida esperada): presentar un nuevo patrón de entrada $x_p = \{x_1, x_2, \dots, x_n\}$ junto con la salida esperada $fd_i(k)$
    3. **Cálculo de la salida actual**: $y(k) = f[w^t x_i - w_{n+1}]$, siendo en este caso f la función de transferencia escalón
    4. **Adaptación de los pesos**: $w_i(k+1) = w_i(k) + \alpha(k)[fd_i(k) - y(k)]x_i$. La salida esperada $fd_i(k)$ es 1 si el patrón pertenece a la clase A y −1 si es de la clase B. La tasa de aprendizaje viene representada por $\alpha(k)$
    5. **Criterio de parada**: si no hay convergencia (pesos cambian), volver al paso 2
  - Decisión:

$$x \in c_i \quad si \quad fd_i(x) > fd_j(x) \quad \forall j = 1,2 \quad j \neq i$$

2. Aprendizaje supervisado: Perceptrón

- **Red neuronal monocapa: Perceptrón simple**
  - Ejemplo
  - Entrenamiento:

	$c_1 \rightarrow +1$			$c_2 \rightarrow -1$		
R	200	210	215	90	92	87
G	160	170	172	130	138	128
B	120	130	133	60	54	66

convergencia

$\alpha = 10^{-4}$ $\quad \|w(k+1) - w(k)\| < \varepsilon \quad$ $\varepsilon = 10^{-4}$

  - Clasificación:

$$A \equiv (208,170,135)$$

2. Aprendizaje supervisado: Perceptrón

- **Red neuronal monocapa: Perceptrón simple**
  - Entrenamiento:
  - Inicialización: $w^t(1) = (0,0,0);\ \alpha = 0.0001$

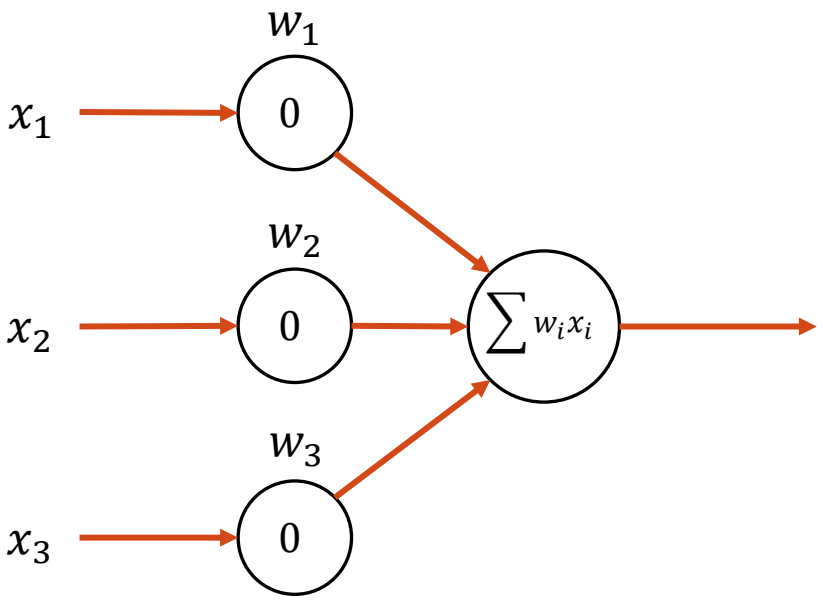

2. Aprendizaje supervisado: Perceptrón

- **Red neuronal monocapa: Perceptrón simple**
  - Entrenamiento:
  - Inicialización: $w^t(1) = (0,0,0);\ \alpha = 0.0001$
  - Iteración 1:
    1. Patrón $x = \{200,160,120\}: w^t x = 0; O = -1,\ \ error = (fd_i - O) = 1 + 1 = 2$ si se modifican los pesos: $w^t(2) = w^t(1) + \alpha(fd_i - O)x = 10^{-3}(40,32,24)$

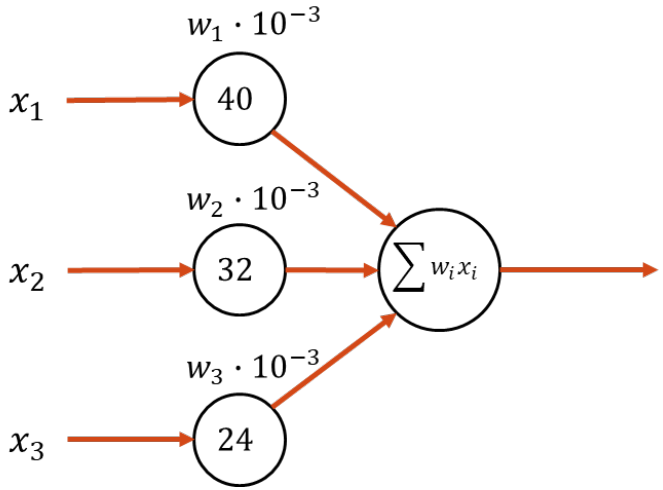

2. Aprendizaje supervisado: Perceptrón

- **Red neuronal monocapa: Perceptrón simple**
  - Entrenamiento:
  - Inicialización: $w^t(1) = (0,0,0);\ \alpha = 0.0001$
  - Iteración 1:
    1. Patrón $x = \{200,160,120\}: w^t x = 0; O = -1,\ error = (fd_i - O) = 1 + 1 = 2$ si se modifican los pesos: $w^t(2) = w^t(1) + \alpha(fd_i - O)x = 10^{-3}(40,32,24)$
    2. Patrón $x = \{210,170,130\}: w^t x = 17; O = 1,\ error = (fd_i - O) = 1 - 1 = 0$ no se modifican los pesos: $w^t(3) = w^t(2)$
    3. Patrón $x = \{215,172,133\}: w^t x = 17; O = 1,\ error = (fd_i - O) = 1 - 1 = 0$ no se modifican los pesos: $w^t(4) = w^t(3)$
    4. Patrón $x = \{90,130,60\}: w^t x = 9.2; O = 1,\ error = (fd_i - O) = -1 - 1 = -2$ si se modifican los pesos: $w^t(5) = w^t(4) + \alpha(fd_i - O)x = 10^{-3}(22,6,12)$
    5. Patrón $x = \{92,138,54\}: w^t x = 3.5; O = 1,\ error = (fd_i - O) = -1 - 1 = -2$ si se modifican los pesos: $w^t(6) = w^t(5) + \alpha(fd_i - O)x = 10^{-3}(4,-22,1)$
    6. Patrón $x = \{87,128,66\}: w^t x = -2.4; O = -1,\ error = (fd_i - O) = -1 + 1 = 0$ no se modifican los pesos: $w^t(7) = w^t(6)$

2. Aprendizaje supervisado: Perceptrón

- **Red neuronal monocapa: Perceptrón simple**
  - Entrenamiento:
  - El proceso converge en la iteración 4, resultando el siguiente vector de pesos:

$$w = 10^{-4}(292, -372, 144)$$

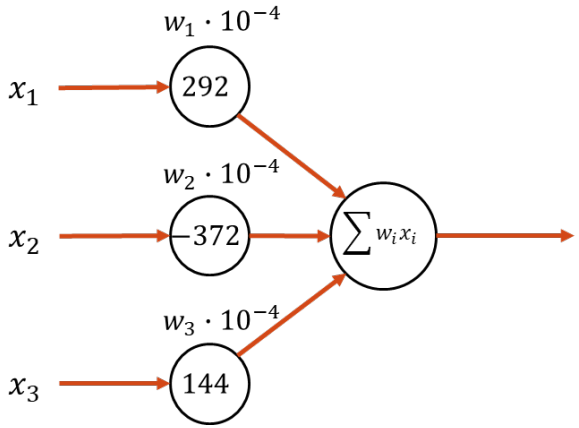

  - Clasificación:
  - Con dicho vector de pesos se clasifican los vectores dados:

$$w^t A = 10^{-4}(292, -372, 144)\begin{pmatrix} 208 \\ 170 \\ 135 \end{pmatrix} = 1.6936 > 0 \rightarrow A\ pertenece\ a\ la\ clase\ c_1$$

2. Aprendizaje supervisado: Perceptrón

- **Red neuronal multicapa: Perceptrón multicapa**
  - La red neuronal multicapa es una generalización de la red neuronal monocapa, la diferencia reside en que mientras la red neuronal monocapa está compuesta por una capa de neuronas de entrada y una capa de neuronas de salida, esta dispone de un conjunto de capas intermedias (capas ocultas) entre la capa de entrada y la de salida
  - Dependiendo del número de conexiones que presente la red, ésta puede estar total o parcialmente conectada

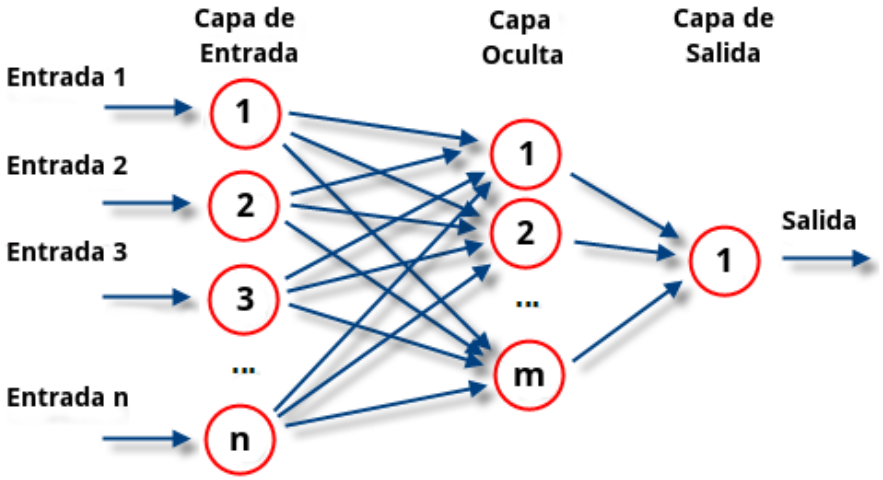

2. Aprendizaje supervisado: Perceptrón

- **Red neuronal multicapa: Perceptrón multicapa**
  - El perceptrón multicapa evoluciona el perceptrón simple y para ello incorpora capas de neuronas ocultas, con esto consigue representar **funciones no lineales**
  - El perceptrón multicapa está compuesto por una capa de entrada, una o varias capas de salida y n capas ocultas entremedias
  - Se caracteriza por tener salidas disjuntas pero relacionadas entre sí, de tal manera que la salida de una neurona es la entrada de la siguiente
  - En el perceptrón multicapa se pueden diferenciar 2 fases:
    - **Propagación:** en la que se calcula el resultado de salida de la red desde los valores de entrada hacia delante
    - **Aprendizaje:** en la que los errores obtenidos a la salida del perceptrón se van propagando hacia atrás (**backpropagation**) con el objetivo de modificar los pesos de las conexiones para que el valor estimado de la red se asemeje cada vez más al real, esta aproximación se realiza mediante la función gradiente del error

Índice de contenidos

3. Aprendizaje no supervisado: K-means

- El algoritmo de $K-means$ es aplicable en los casos en que tengamos una representación de nuestros datos como elementos en un espacio métrico
- El algoritmo de $K-means$ intenta encontrar una partición de las muestras en K agrupaciones, de forma que cada ejemplo pertenezca a una de ellas, concretamente a aquella cuyo centroide esté más cerca
- El mejor valor de K para que la clasificación separe lo mejor posible los ejemplos no se conoce a priori, y depende completamente de los datos con los que trabajemos

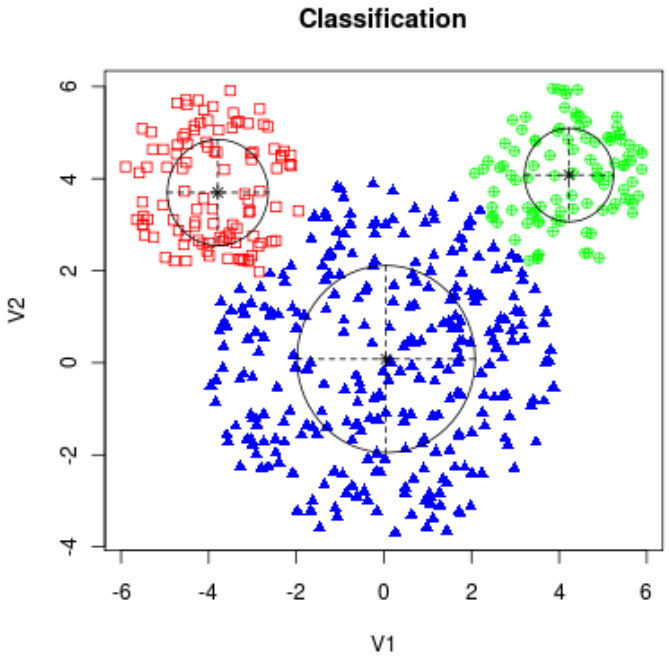

3. Aprendizaje no supervisado: K-means

- En este caso, **no tenemos un conocimiento a priori** que nos indique cómo deben agruparse ninguno de los datos de que disponemos, es decir, **no hay un protocolo externo que nos indique lo bien o mal que vamos a realizar la tarea**, ningún criterio supervisa la bondad de nuestras soluciones
- Pero eso no significa que nosotros no podamos introducir una medida de bondad, aunque sea artificial y subjetiva
- En este caso, el algoritmo de $K-means$ va a intentar minimizar la varianza total del sistema, es decir, si c_i es el centroide de la agrupación i-ésima, y $\{x_j^i\}$ es el conjunto de ejemplos clasificados en esa agrupación, entonces intentamos minimizar la función:

$$\sum_i \sum_j d(x_j^i, c_i)^2$$

3. Aprendizaje no supervisado: K-means

- Intuitivamente, cuanto más pequeño sea este valor, más agrupados están los ejemplos en esos conjuntos
- Pero observemos que el número de conjuntos no viene dado por el algoritmo, sino que hemos de decidirlo antes de ejecutarlo
- A pesar de que el problema se plantea como una optimización, existe un algoritmo muy sencillo que devuelve un resultado similar
- Fijado K, los pasos que sigue el algoritmo son los siguientes:
    1. Seleccionar al azar K puntos del conjunto de datos como centros iniciales de los grupos
    2. Asignar el resto de ejemplos al centro más cercano (tenemos K agrupaciones iniciales)
    3. Calcular el centroide de los grupos obtenidos
    4. Reasignar los centros a estos centroides
    5. Repetir desde el paso 2 hasta que no haya reasignación de centros (o los últimos desplazamientos estén por debajo de un umbral y no haya cambios en las agrupaciones obtenidas)

https://youtu.be/74rv4snLl70

Índice de contenidos

3. Aprendizaje no supervisado: SOM

- Un modelo SOM (Self-Organizing Maps) está compuesto por dos capas de neuronas
- La capa de entrada (formada por N neuronas, una por cada variable de entrada) se encarga de recibir y transmitir a la capa de salida la información procedente del exterior
- La capa de salida (formada por M neuronas) es la encargada de procesar la información y formar el mapa de rasgos

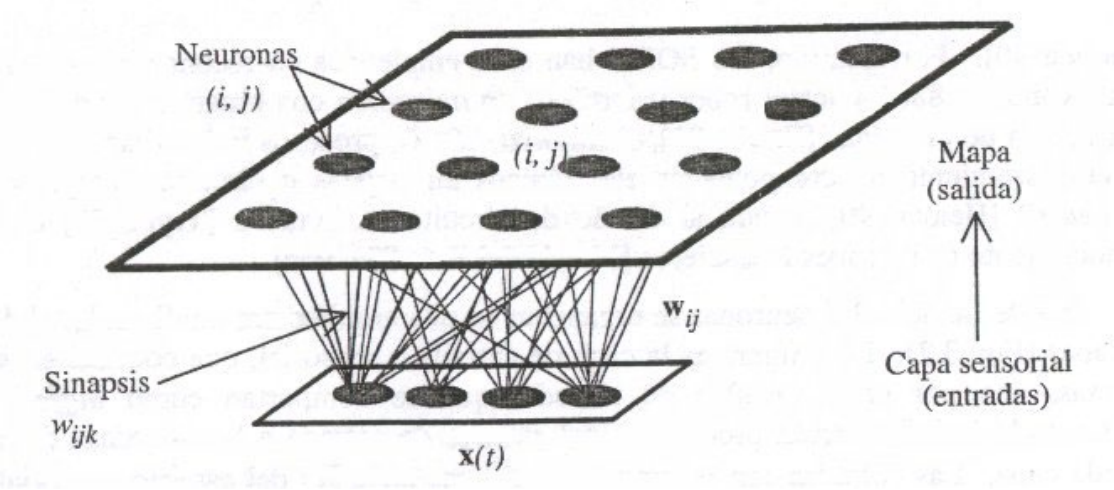

3. Aprendizaje no supervisado: SOM

- Las conexiones entre las dos capas que forman la red son siempre hacia delante, es decir, la información se propaga desde la capa de entrada hacia la capa de salida
- Cada neurona de entrada i está conectada con cada una de las neuronas de salida j mediante un peso w_{ij}
- Las neuronas de salida tienen asociado un vector de pesos W_j llamado vector de referencia (o *codebook*), debido a que constituye el vector prototipo (o promedio) de la categoría representada por la neurona de salida j
- Las neuronas adyacentes pertenecen a una vecindad N_j de la neurona j

3. Aprendizaje no supervisado: SOM

- La topología y el número de neuronas permanece fijo desde el principio
- El número de neuronas determina la suavidad de la proyección, lo cual influye en el ajuste y capacidad de generalización del SOM
- Durante la fase de entrenamiento, el SOM forma una red elástica que se pliega dentro de la nube de datos originales. El algoritmo controla la red de modo que tiende a aproximar la densidad de los datos
- Los vectores de referencia del *codebook* se acercan a las áreas donde la densidad de datos es alta

3. Aprendizaje no supervisado: SOM

- Algoritmo de Kohonen:
  - **Paso 1.** Un vector x es seleccionado al azar del conjunto de datos y se calcula su distancia (similitud) a los vectores de referencia, usando, por ejemplo, la distancia euclídea:

$$\|x - m_c\| = \min_j \{\|x - m_j\|\}$$

  - **Paso 2.** Una vez que se ha encontrado el vector más próximo o BMU (Best Matching Unit) el resto de los vectores de referencia se actualizan. El BMU y sus vecinos (en sentido topológico) se mueven cerca del vector x en el espacio de datos. La magnitud de dicha atracción está regida por la *tasa de aprendizaje* α
  - Mientras se va produciendo el proceso de actualización y nuevos vectores se asignan al mapa, la tasa de aprendizaje decrece gradualmente hacia cero. Junto con ella también decrece el radio de vecindad también
  - La regla de actualización para el vector de referencia dado i es la siguiente:

$$m_j(t+1) = \begin{cases} m_j(t) + \alpha(t)\left(x(t) - m_j(t)\right) & j \in N_c(t) \\ m_j(t) & j \notin N_c(t) \end{cases}$$

3. Aprendizaje no supervisado: SOM

- Algoritmo de Kohonen:
  - Los pasos 1 y 2 se van repitiendo hasta que el entrenamiento termina. El número de pasos de entrenamiento se debe fijar antes a priori, para calcular la tasa de convergencia de la función de vecindad y de la tasa de aprendizaje
  - Una vez terminado el entrenamiento, el mapa ha de ordenarse en sentido topológico: n vectores topológicamente próximos se aplican en n neuronas adyacentes o incluso en la misma neurona

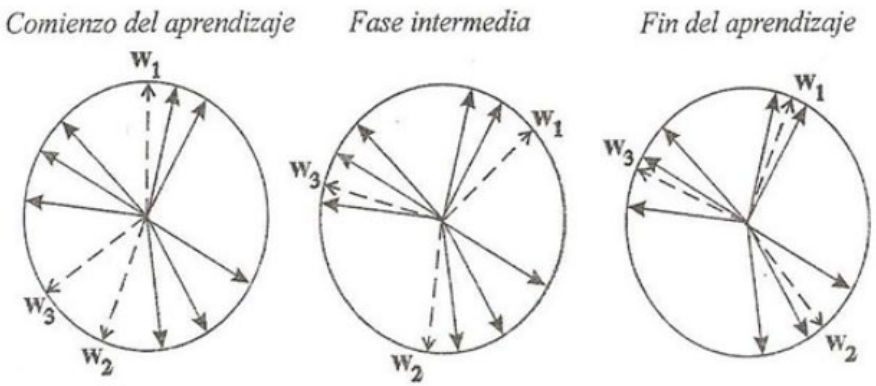

3. Aprendizaje no supervisado: SOM

- Medidas de calidad del mapa y precisión del mapa:
  - Una vez que se ha entrenado el mapa, es importante saber si se ha adaptado adecuadamente a los datos de entrenamiento. Como medidas de calidad de los mapas se considera la precisión de la proyección y la preservación de la topología
  - La medida de precisión de la proyección describe cómo se adaptan o responden las neuronas a los datos. Habitualmente, el número de datos es mayor que el número de neuronas y el error de precisión es siempre diferente de 0
  - Para calcular la precisión de la proyección se usa el error medio de cuantificación sobre el conjunto completo de datos:

$$\varepsilon_q = \frac{1}{N}\sum_{i=1}^{N}\left\|x_i - m_{BMU(i)}\right\|$$

3. Aprendizaje no supervisado: SOM

- Medidas de calidad del mapa y precisión del mapa:
  - La medida de preservación de la topología describe la manera en la que el SOM preserva la topología del conjunto de datos. Esta medida considera la estructura del mapa. En un mapa que esté *retorcido* de manera extraña, el error topográfico es grande incluso si el error de precisión es pequeño
  - Una manera simple de calcular el error topográfico es:

$$\varepsilon_t = \frac{1}{N}\sum_{i=1}^{N} u(x_i)$$

donde $u(x_i)$ es igual a 1 si el primer y segundo BMUs de x_i no están próximos el uno al otro. De otro modo, $u(x_i)$ es igual a 0

3. Aprendizaje no supervisado: SOM

- Medidas de calidad del mapa y precisión del mapa:
  - ε_q bajo: los datos están bien representados por las neuronas
  - ε_q alto: las neuronas no se han ajustado bien a los datos (la resolución del mapa es insuficiente o el entrenamiento no ha sido adecuado)
  - ε_t bajo: la estructura del mapa respeta bien la topología de los datos originales
  - ε_t alto: la organización del mapa es deficiente y se han producido distorsiones topológicas

3. Aprendizaje no supervisado: SOM

- Ejemplo (datos del MNIST):
  - Aprendizaje de números escritos a mano
  - 10 clases posibles, dígitos del cero al nueve (imágenes 28x28)
  - El rango de las imágenes tenemos que varía entre 0 y 255, se normaliza

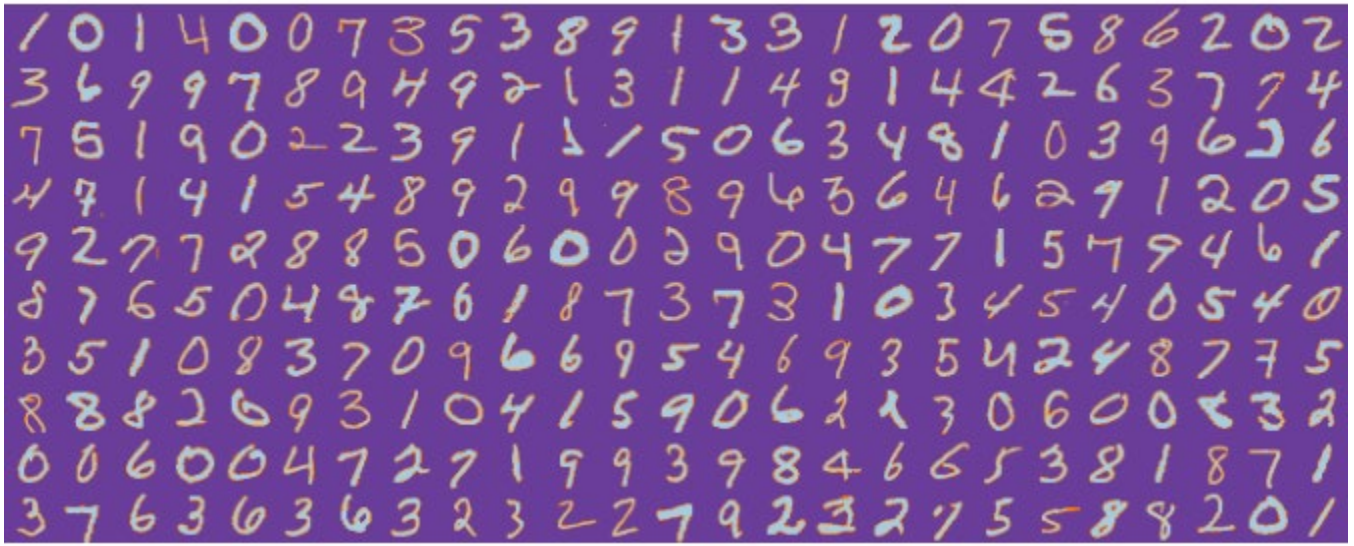

3. Aprendizaje no supervisado: SOM

- Ejemplo (datos del MNIST):
  - Entrenamiento con 29404 muestras
  - Número de iteraciones 100
  - Tasa de aprendizaje α comienza en 0.7 y decrece hasta 0.01
  - Vecindad circular de radio 7
  - Capa de salida formada por 10x10 elementos

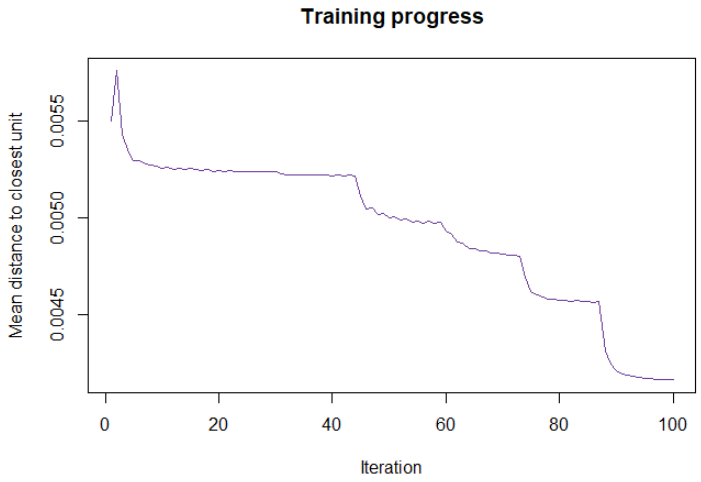

3. Aprendizaje no supervisado: SOM

- Ejemplo (datos del MNIST):
  - *codebook* del modelo: refleja cómo influye cada uno de los 784 píxeles a cada una de las neuronas de salida. Se observa que neuronas cercanas tienden a tener distribuciones similares

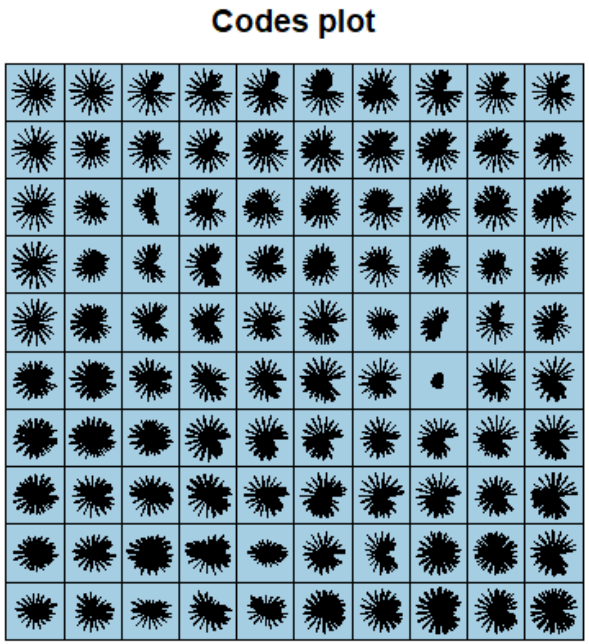

3. Aprendizaje no supervisado: SOM

- Ejemplo (datos del MNIST):
  - Ahora observando las **zonas del mapa asociada a cada clase** tenemos que cada clase se ubica en zonas relativamente diferentes del resto de las clases, esto indica que el modelo separa las características que diferencian a cada clase

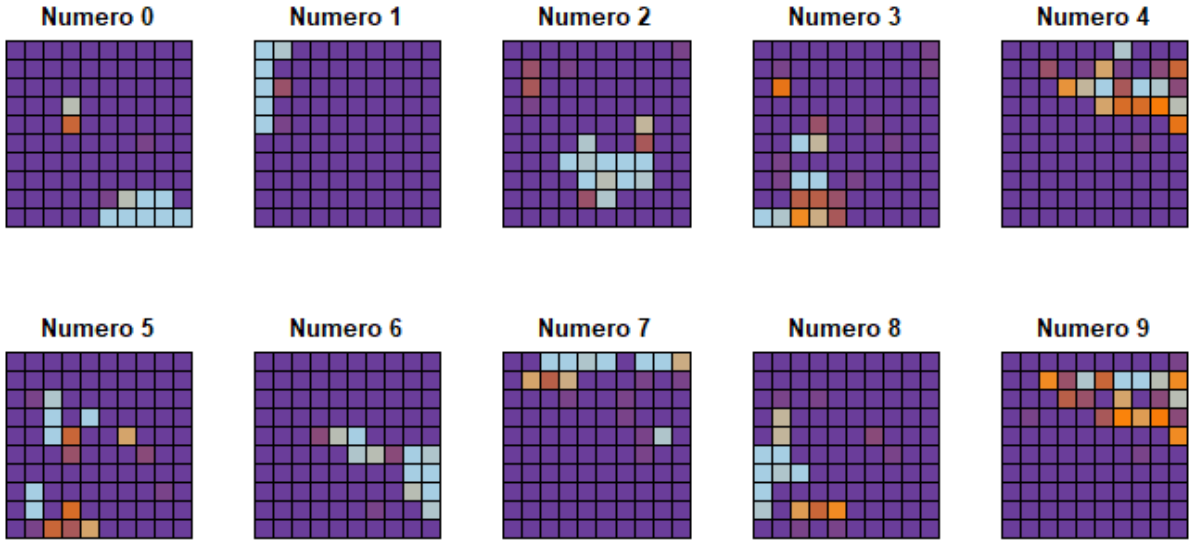

3. Aprendizaje no supervisado: SOM

- Ejemplo (datos del MNIST):
  - Se observa que **cada clase activa neuronas específicas**, ahora vamos a ver si estas distribuciones están relacionadas o no y por lo tanto si el mapa es útil para extraer características que diferencien cada clase
  - Al realizar la **correlación** entre los datos tenemos que los datos generados por el modelo para cada clase no están correlacionados, lo que es muy útil para clasificar
  - Los números con mayor correlación son el 4 y el 9 con una correlación 0.253

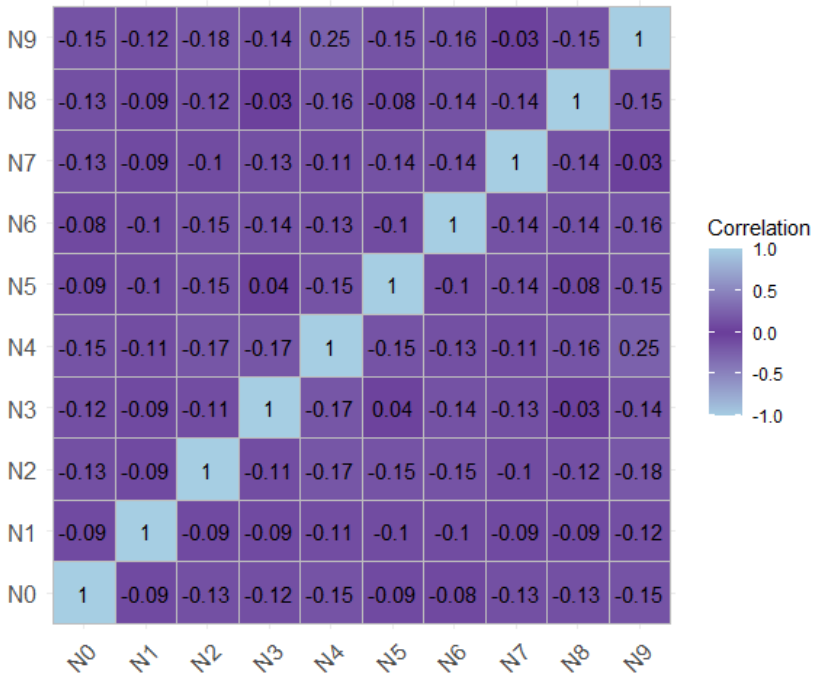

3. Aprendizaje no supervisado: SOM

- Ejemplo (datos del MNIST):
  - Como se observa en la matriz de confusión, los números 4 y 9 presentan algunos problemas, así como el 3 y el 8 con el numero 5. Estos números corresponden a las zonas conflictivas de la anterior
  - De todas maneras, la clasificación entrega un valor de precisión igual a 0.849 y un valor de kappa igual a 0.8322 lo que es bastante bueno para ser un modelo no supervisado

```
Confusion Matrix and Statistics

          Reference
Prediction    0    1    2    3    4    5    6    7    8    9
         0 1165    0   12   20    0   30   30    2    3    6
         1    0 1366   16    2    9    3    2   13    6    5
         2   18    5 1117   21   23   36   31   31   18   14
         3    4   15   23 1047    0  150    1    1   51   11
         4    2    1    4    1  867    8    1   26   12  174
         5   20    2    1   82    4  859    5    3   92   12
         6   25    2   11    4   20   20 1168    0    8    3
         7    2    2   32   16   11    2    0 1130    7   43
         8    3    6   37   95    1   16    3   10  999   12
         9    0    6    0   17  286   14    0  104   22  976
```

```
Overall Statistics

               Accuracy : 0.849
                 95% CI : (0.8426, 0.8552)
    No Information Rate : 0.1115
    P-Value [Acc > NIR] : < 2.2e-16

                  Kappa : 0.8322
```

3. Aprendizaje no supervisado: SOM

- Ejemplo (datos del MNIST):
  - La **desviación estándar** de cada neurona por clase presenta algunas **zonas conflictivas**
  - El color morado representa una desviación máxima y a medida que se acerca al celeste (pasando por naranja) se acerca a 0
  - Las neuronas con **menor desviación** por clase se muestran en tonos naranja y celeste, estas representan zonas difusas donde se ubican **características más generales y pueden pertenecer a varias clases**, por lo que genera desviación menor entre clases
  - En este caso particular las zonas con baja desviación están asociadas por un lado una zona grande del 9 y el 4, donde hasta un ser humano podría tener problemas en diferenciar; por otro en una zona menor asociada al 3, 5 y 8, números que también podrían llegar a ser confundidos

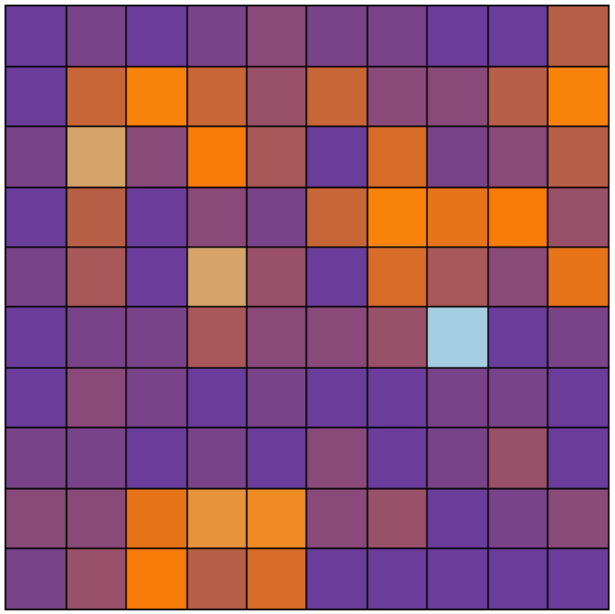

3. Aprendizaje no supervisado: SOM

- Otros ejemplos:
- Números pares o impares

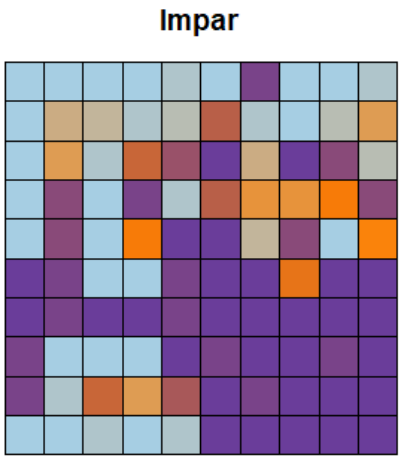

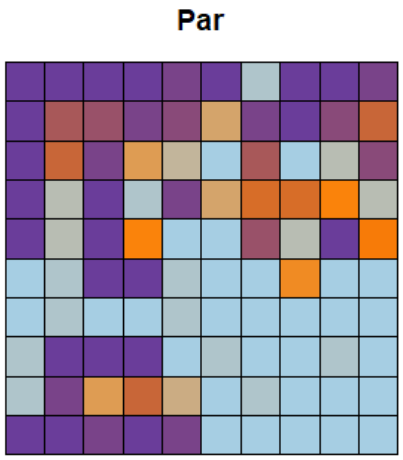


```
Confusion Matrix and Statistics

          Reference
Prediction    0    1
         0 5881  594
         1  543 5578

               Accuracy : 0.9097
                 95% CI : (0.9046, 0.9147)
    No Information Rate : 0.51
    P-Value [Acc > NIR] : <2e-16

                  Kappa : 0.8194
```

3. Aprendizaje no supervisado: SOM

- Otros ejemplos:
- Reconocimiento facial

3. Aprendizaje no supervisado: SOM

- Otros ejemplos:
- Reconocimiento facial

```
Confusion Matrix and Statistics

          Reference
Prediction  A  B  C  D  E  F  G  H  I  J  K  L  M
         A 22  1  0  0  1  0  0  0  0  0  0  0  0
         B  0 21  0  0  0  0  0  0  0  0  0  0  0
         C  0  0 22  0  0  0  0  0  0  0  0  0  0
         D  0  0  0 22  0  0  0  0  0  0  0  0  0
         E  0  0  0  0 16  0  0  0  0  0  0  0  0
         F  0  0  0  0  0 22  0  0  0  0  0  0  0
         G  0  0  0  0  0  0 22  0  0  0  0  0  0
         H  0  0  0  0  0  0  0 22  0  0  0  0  0
         I  0  0  0  0  0  0  0  0 22  0  0  0  0
         J  0  0  0  0  0  0  0  0  0 22  0  0  0
         K  0  0  0  0  0  0  0  0  0  0 22  0  0
         L  0  0  0  0  0  0  0  0  0  0  0 22  0
         M  0  0  0  0  5  0  0  0  0  0  0  0 22

Overall Statistics

               Accuracy : 0.9755
                 95% CI : (0.9502, 0.9901)
    No Information Rate : 0.0769
    P-Value [Acc > NIR] : < 2.2e-16

                  Kappa : 0.9735
```

3. Aprendizaje no supervisado: SOM

- Otros ejemplos:
- Reconocimiento expresión facial

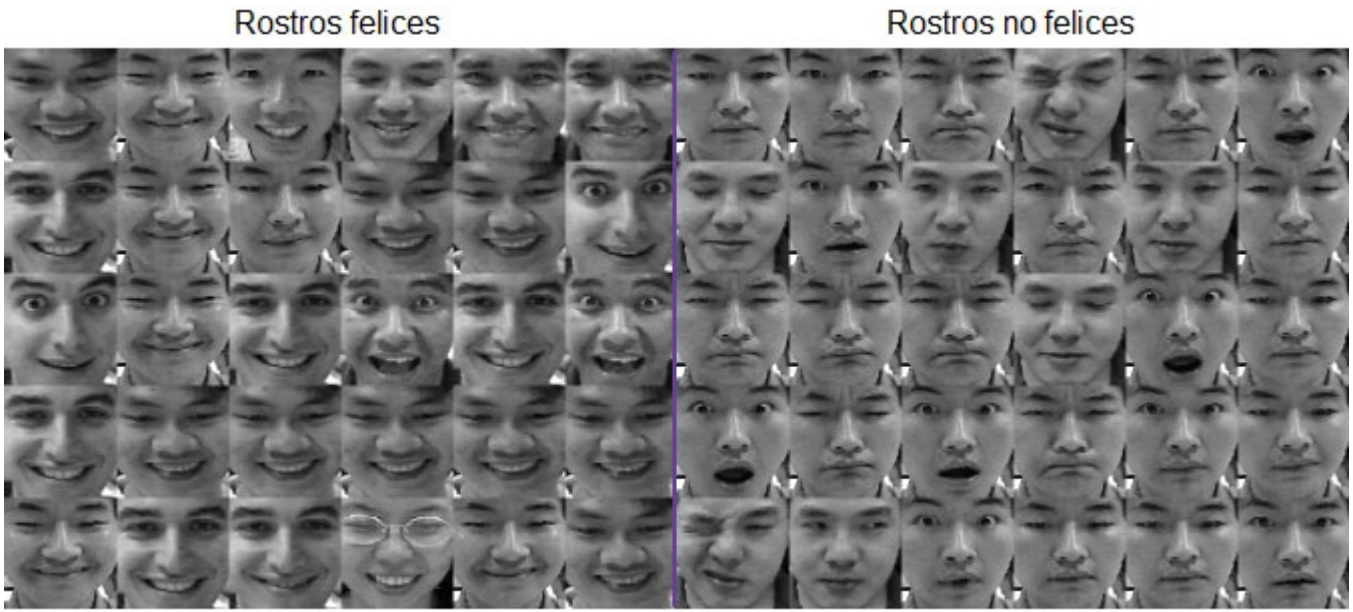

3. Aprendizaje no supervisado: SOM

- Otros ejemplos:
- Reconocimiento expresión facial

No feliz

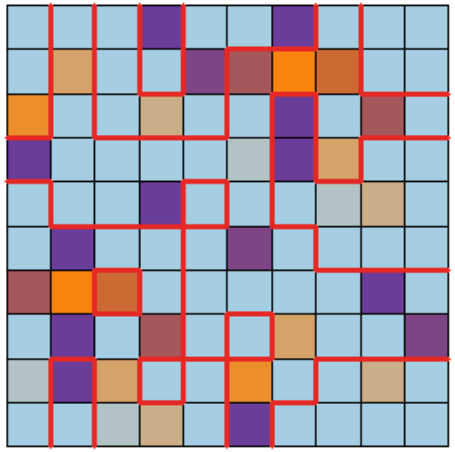

Feliz

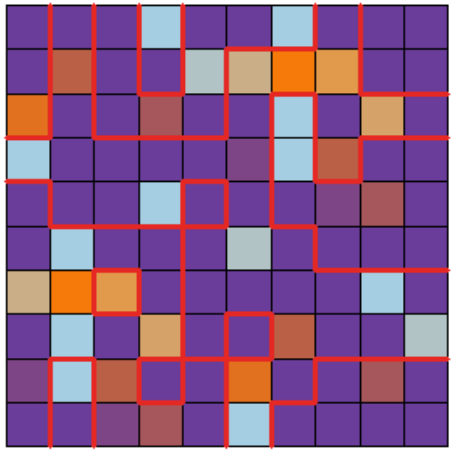

```
Confusion Matrix and Statistics

          Reference
Prediction   0   1
         0 224  20
         1   9  33

               Accuracy : 0.8986
                 95% CI : (0.8576, 0.931)
    No Information Rate : 0.8147
    P-Value [Acc > NIR] : 6.7e-05

                  Kappa : 0.6349
```

Índice de contenidos

4. Deep learning

- Cuando se trata de la detección de objetos basada en el aprendizaje profundo, hay dos detectores de objetos principales:
  - **Detectores de dos etapas**: primero generan regiones candidatas y luego las clasifican (R-CNN y sus variantes, Fast R-CNN y Faster R-CNN, Mask R-CNN)
    - Ventaja: alta precisión
    - Desventaja: más lentos, menos aptos para tiempo real
  - **Detectores de una sola etapa**: detectan y clasifican objetos en una única pasada por la red (SSD: Single Shot Detector, YOLO: You Only Look Once)
    - Ventaja: muy rápidos, ideales para aplicaciones en tiempo real
    - Desventaja: a veces menos precisos, especialmente en objetos pequeños (aunque esto ha mejorado en versiones recientes)

4. Deep learning: R-CNN

- Los R-CNN (Region Based Convolutional Neural Networks) son uno de los primeros detectores de objetos basados en aprendizaje profundo y son un ejemplo de un detector de dos etapas:
  - En la **primera aproximación** (Girshick et al., 2013) se propuso un detector de objetos que requería un algoritmo como la búsqueda selectiva (o equivalente) para proponer Bounding boxes candidatos que pudieran contener objetos
  - Luego, estas regiones se pasan a una CNN para su clasificación, lo que finalmente condujo a uno de los primeros detectores de objetos basados en aprendizaje profundo
- El problema del método estándar era su lentitud ya que no se trata de un detector de objetos completo de extremo a extremo

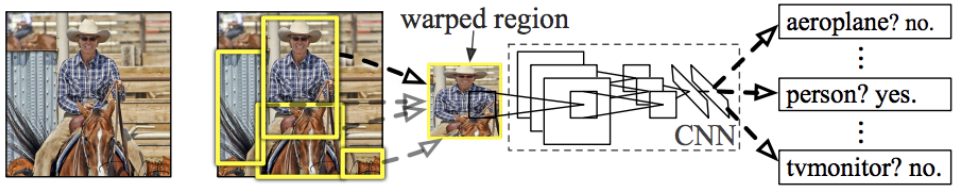

4. Deep learning: R-CNN

- En 2015, Girshick et al. propusieron el algoritmo Fast R-CNN, que mejoró significativamente el R-CNN original, aumentando la precisión y reduciendo el tiempo de inferencia. Sin embargo, el modelo aún dependía de un algoritmo externo para la propuesta de regiones.
- No fue hasta el artículo de seguimiento de 2015 que las R-CNN se convirtieron en un verdadero detector de objetos de aprendizaje profundo de extremo a extremo, eliminando la necesidad de búsqueda selectiva y reemplazándola con una Red de Propuestas de Región (RPN). Esta RPN es (1) **completamente convolucional** y (2) capaz de **predecir tanto las cajas delimitadoras de los objetos como las puntuaciones de "objetividad"**, que indican la probabilidad de que una región de la imagen contenga un objeto.
- Las salidas de la RPN se pasan luego al componente R-CNN para su clasificación y etiquetado final

4. Deep learning: Yolo

- Aunque las **R-CNN** son **muy precisas**, su principal **desventaja** es la **lentitud**: alcanzaban solo 5 FPS incluso en una GPU
- Para mejorar la velocidad de los detectores de objetos basados en aprendizaje profundo, tanto el SSD como YOLO utilizan una estrategia de detección de una sola etapa
- Estos algoritmos abordan la detección de objetos como un **problema de regresión**, aprendiendo simultáneamente las coordenadas de los cuadros delimitadores y las probabilidades de las etiquetas de clase correspondientes a partir de una imagen de entrada
- En general, los **detectores de una etapa** suelen ser **menos precisos** que los de dos etapas, pero son considerablemente **más rápidos**
- YOLO es uno de los ejemplos más destacados de un detector de una sola etapa

4. Deep learning: Yolo

- En 2015, Redmon et al. presentaron un detector de objetos capaz de realizar detecciones en tiempo real de manera impresionante, alcanzando 45 FPS en una GPU
- Además, una variante más pequeña de su modelo, conocida como 'Fast YOLO', afirma alcanzar 155 FPS en una GPU
- YOLO ha pasado por diversas iteraciones, incluida YOLO9000 (una mejora significativa que se conoce como YOLOv2), que es capaz de detectar más de 9000 clases de objetos
- Redmon y Farhadi lograron una gran capacidad de detección al realizar un entrenamiento conjunto tanto para detección como para clasificación de objetos.
- En este proceso, entrenaron YOLO9000 simultáneamente en los conjuntos de datos de clasificación de ImageNet y de detección de COCO, lo que permitió que el modelo predijera detecciones para clases de objetos incluso sin datos etiquetados para la detección

4. Deep learning: Yolo

- Aunque YOLOv2 fue un avance interesante y novedoso, su desempeño fue algo decepcionante dado el título y el resumen del artículo: de las 156 clases del conjunto de datos COCO, YOLO9000 alcanzó un 16% de precisión promedio (mAP)
- En 2018, Redmon y Farhadi publicaron YOLOv3, un modelo significativamente más grande que sus predecesores, pero que se ha convertido en el mejor de la familia YOLO
- El conjunto de datos COCO, que cuenta con 80 categorías, incluye una amplia variedad de clases, como: personas, bicicletas, coches, camiones, aviones, señales de STOP, bocas de incendio, animales (gatos, perros, pájaros, caballos, vacas, ovejas, etc.), objetos de cocina y comedor (copas de vino, tazas, tenedores, cuchillos, cucharas, etc.), entre muchas otras
- Actualmente el modelo más avanzado es Ultralytics YOLOv11 (enlace)

4. Deep learning: Yolo

- En YOLO, toda la imagen se introduce en el modelo, y esa es una de las principales razones por las que es tan rápido. El modelo mira la imagen completa solo una vez y realiza todas las predicciones en una sola pasada a través de la red neuronal convolucional (CNN)
- Este proceso lo hace la CNN, donde cada porción de la convolución corresponde a una **celda de la cuadrícula**. Por ejemplo, la **celda superior derecha** de la imagen se relaciona con la parte superior derecha de los filtros de cada capa. Esta visualización está representada a la izquierda de la imagen:

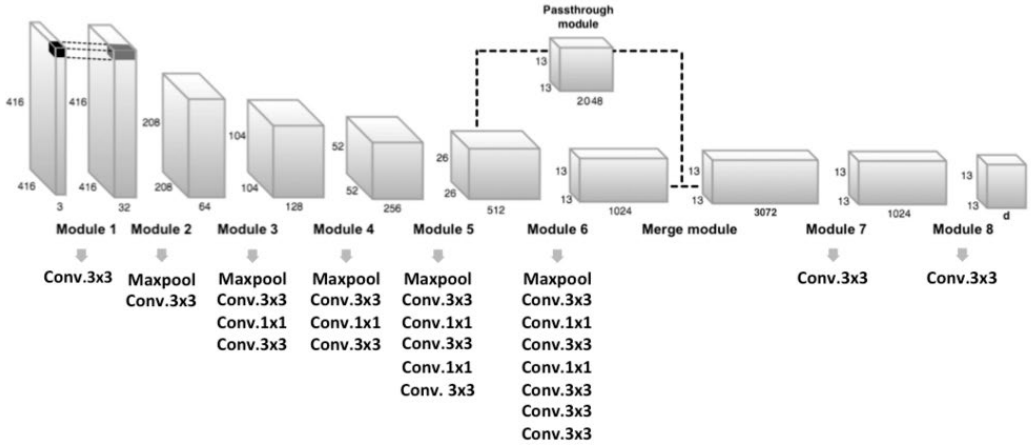

4. Deep learning: Yolo

1. Optimización del modelo:
   - Durante el entrenamiento, YOLO optimiza los pesos de la red para mejorar la precisión de las detecciones utilizando una función de pérdida que tiene en cuenta tanto la precisión de la detección de los cuadros delimitadores como la clasificación de los objetos
2. División de la imagen en cuadrículas:
   - YOLO divide la imagen en una cuadrícula de celdas
   - Cada celda de la cuadrícula se encarga de predecir un conjunto fijo de cuadros delimitadores (bounding boxes) y las probabilidades asociadas con las clases de objetos
3. Predicción de cuadros delimitadores y clases:
   - Para cada celda predice sobre los cuadros delimitadores que contienen los objetos
   - Se asocia a cada cuadro un puntuaje de confianza que indica la certeza de que el cuadro delimitador contiene un objeto y una probabilidad para cada clase de objeto posible
4. Supresión de no máximos:
   - Después de las predicciones, YOLO aplica la supresión de no máximos para eliminar detecciones redundantes y mantener solo las más confiables
   - Se comparan los puntajes de confianza de los cuadros delimitadores y se eliminan aquellos que tienen una alta superposición con cuadros delimitadores más confiables

4. Deep learning: Yolo